CNN (DenseNet-121) vs. Transformers (DeiT-S vs. Swin-T) vs. Híbrido (CoAtNet-0) en radiografías de tórax

Néstor Issel Hernández Rojo
Maestría en Inteligencia Artificial, Módulo 8: Aprendizaje Profundo
Universidad Panamericana
0287452@up.edu.com

I. Introducción y motivación

La radiografía de tórax es el estudio de imagen más solicitado, y leerla exige una experiencia que no siempre está disponible. Desde CheXNet [1], la referencia son las redes convolucionales (CNN). Los Transformers de visión [2] deben aprender de los datos la noción de vecindad que la convolución trae de fábrica, y por eso piden más datos o un mejor preentrenamiento [3], [4]. Mis resultados con el 100 % de los pacientes lo respaldan: DenseNet-121 [5], Swin-T [6] y CoAtNet-0 [7], que conservan la vecindad, quedan muy cerca en AUROC, y el Transformer puro DeiT-S queda 0.020 abajo.

Esto importa en la clínica, donde un clasificador puede indicar qué estudios leer primero, y en la práctica, porque las cifras publicadas no son comparables: cada trabajo usa su propia separación de pacientes, su preentrenamiento y su receta [3], [4], [8]. Aquí solo cambia la arquitectura. La pregunta es: ¿qué familia conviene en ChestX-ray14, a qué costo y por qué? Mis contribuciones son:

1. Una comparación de las cuatro familias con el 100 % de los pacientes, con una DenseNet-121 implementada capa por capa.
2. Una evaluación más allá del AUROC: F1, calibración, costo, convergencia, generalización y líneas base sin imagen.
3. Grad-CAM [9] medido contra 984 cajas de radiólogos.

II. Estado del arte

ChestX-ray14 [8] reúne 112,120 radiografías de tórax con 14 etiquetas extraídas automáticamente de los informes. Sobre ella, CheXNet [1], una DenseNet-121 [5], llegó a 0.841 de AUROC, aunque con una separación al azar, distinta de la oficial que uso (Tabla I).

Los Transformers de visión cambian la convolución por atención entre parches. DeiT [2] se entrena sin bases de datos gigantes; Swin [6] limita la atención a ventanas de parches vecinos, y CoAtNet [7] usa convoluciones al principio y atención al final.

Los estudios que usan la separación oficial coinciden en que los Transformers alcanzan a las CNN solo con un buen preentrenamiento. Ma *et al.* [3] muestran que, entrenados desde cero, un ViT-B pierde 0.08 de AUROC y una ResNet-50 solo 0.013; Xiao *et al.* [4] reportan 0.822 para DenseNet-121 y 0.796 para ViT-S, ambos con ImageNet. Grad-CAM [9] muestra en qué zona se apoya cada modelo.

Tabla I
AUROC PROMEDIO DE REFERENCIA EN CHESTX-RAY14

Trabajo	Modelo (preentrenamiento)	Separación	AUROC
Wang *et al.* [8]	ResNet-50	aleatoria	0.738
CheXNet [1]	DenseNet-121 (ImageNet)	aleatoria	0.841
Ma *et al.* [3]	Swin-B (ImageNet-1k)	oficial	0.817
Ma *et al.* [3]	Swin-B (ImageNet $\rightarrow$ RX)	oficial	0.830
Xiao *et al.* [4]	DenseNet-121 (ImageNet)	oficial	0.822
Xiao *et al.* [4]	ViT-S (ImageNet)	oficial	0.796
Xiao *et al.* [4]	ViT-S (MAE con RX)	oficial	0.823

Promedio de las 14 enfermedades; un clasificador al azar da 0.500. [1], [8] separan los datos al azar por paciente y no son comparables con la separación oficial que usa este trabajo. RX: radiografías.

III. Metodología

A. Datos

ChestX-ray14 tiene 112,120 radiografías frontales de 30,805 pacientes; cada una puede tener varias de las 14 enfermedades o ninguna. Usé la separación oficial por paciente: 86,524 imágenes para entrenamiento y validación, y 25,596 (2,797 pacientes) para test. Del primer grupo aparté el 10 % de los pacientes para validación (8,536 imágenes); el resto (25,207 pacientes, 77,988 imágenes) es el entrenamiento. Separar por paciente evita que la red "reconozca" a una persona en lugar de la enfermedad. Usé las imágenes de 224×224 píxeles y escalé por $224/1024$ las cajas de los radiólogos.

El desbalance es fuerte (Fig. 1): Infiltration aparece en 16 % de las imágenes y Hernia en 0.16 %. Además, el test oficial es otra población: 39 % de sus imágenes no tiene hallazgos, contra 58 % en entrenamiento.

B. Preprocesamiento, aumento de datos y balanceo de clases

Normalización. Copié la radiografía, en escala de grises, en los tres canales que esperan los pesos de ImageNet, la llevé a $[0, 1]$ y normalicé cada canal con la media y la desviación estándar con que se preentrenó cada red, $\tilde{x} = (x - \mu)/\sigma$: $\mu = (0.485, 0.456, 0.406)$ y $\sigma = (0.229, 0.224, 0.225)$, salvo en CoAtNet-0, que usa $\mu = \sigma = 0.5$.

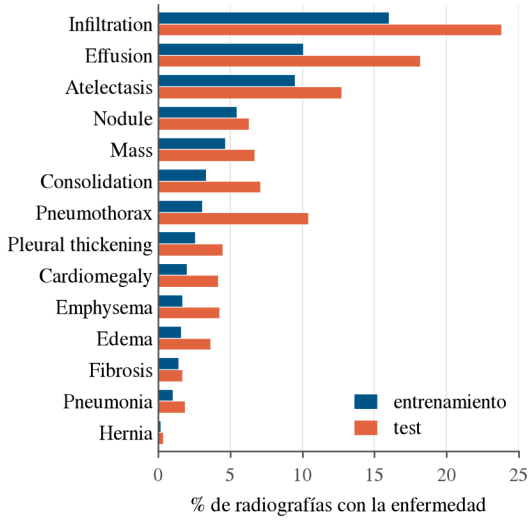


Fig. 1. Porcentaje de radiografías con cada enfermedad en entrenamiento y en el test oficial.

Aumento de datos. Solo en entrenamiento, cada radiografía recibe tres transformaciones al azar que imitan la variación real entre estudios: un recorte de 80 % a 100 % del área (relación ancho/alto de 0.9 a 1.1), llevado de nuevo a 224×224; una rotación por un ángulo $\varphi \in [-7°, 7°]$, por un paciente un poco girado, que lleva el píxel (u, v), medido desde el centro, a

$$\begin{pmatrix} u' \\ v' \end{pmatrix} = \begin{pmatrix} \cos\varphi & -\sin\varphi \\ \sin\varphi & \cos\varphi \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}; \tag{1}$$

y, por la exposición del equipo, un cambio de brillo, $x' = a\,x$, y uno de contraste, $x' = \bar{x} + c\,(x - \bar{x})$, con $\bar{x}$ el gris medio y $a, c \in [0.9, 1.1]$ al azar. No volteé la imagen: el corazón está a la izquierda del paciente, y voltearla crearía una anatomía que casi no existe. En la Sección IV-G mido el efecto de estas decisiones en una muestra de pacientes.

Balanceo de clases. Casi todas las respuestas son "no": Hernia aparece en solo 122 de las 77,988 radiografías de entrenamiento. Si todos los errores pesaran igual, a la red le convendría decir siempre "no" y nunca aprendería las enfermedades raras. Por eso ponderé la pérdida: cada caso positivo de la enfermedad c pesa w_c veces lo que pesa un negativo:

$$w_c = \sqrt{\frac{N_c^-}{N_c^+}}, \tag{2}$$

donde N_c^+ es el número de radiografías de entrenamiento que tienen la enfermedad c (positivos) y N_c^- el de las que no la tienen (negativos), aunque tengan otra enfermedad; para Hernia, 122 y 77,866. Sin la raíz, cada caso de Hernia pesaría 638 veces más que un negativo y unos cuantos casos dominarían el entrenamiento. Con la raíz, Hernia pesa 25, Pneumonia 10 e Infiltration, la más común, 2.3: lo suficiente para no ignorar las enfermedades raras sin volver inestable el entrenamiento.

C. Cómo aprende la red

La Fig. 2 resume el ciclo de entrenamiento.

Punto de partida. Cada red empieza con los pesos θ_0 que aprendió en ImageNet (1.28 millones de fotografías), cuyas primeras capas ya detectan bordes y texturas. Solo cambié la última capa por una nueva de 14 salidas, una por enfermedad, y entrené todos los pesos (ajuste fino): es el aprendizaje por transferencia.

Paso hacia adelante (*forward*). Para una radiografía x, la red produce 14 números $z_c = f_\theta(x)_c$ (logits), y cada uno se convierte en probabilidad con la sigmoide, $p_c = \sigma(z_c) = 1/(1+e^{-z_c})$. Cada enfermedad es una pregunta independiente de sí o no; por eso usé la sigmoide y no la softmax, que obligaría a elegir una sola enfermedad.

Pérdida. Para cada radiografía usé la entropía cruzada binaria ponderada con (2):

$$\mathcal{L} = -\frac{1}{14}\sum_{c=1}^{14}\Big[w_c\,y_c\log p_c + (1-y_c)\log(1-p_c)\Big], \tag{3}$$

donde $y_c \in \{0, 1\}$ es la etiqueta. Como $\sigma'(z) = \sigma(z)\,(1 - \sigma(z))$, la sigmoide y el logaritmo se simplifican y la derivada respecto al logit queda:

$$\frac{\partial \mathcal{L}}{\partial z_c} = \frac{1}{14}\Big[(w_c\,y_c + 1 - y_c)\,p_c - w_c\,y_c\Big]. \tag{4}$$

Si la enfermedad está presente ($y_c = 1$), el gradiente vale $w_c(p_c - 1)/14$: empuja p_c hacia arriba con una fuerza multiplicada por w_c. Si no está, vale $p_c/14$ y empuja hacia abajo. Así, un caso raro de Hernia "grita" 25 veces más fuerte.

Retropropagación (*backward*). La regla de la cadena lleva ese gradiente hacia atrás, capa por capa: si $h_\ell = f_\ell(h_{\ell-1})$ es la salida de la capa ℓ, el gradiente que llega a la capa anterior es $\partial\mathcal{L}/\partial h_{\ell-1} = (\partial h_\ell/\partial h_{\ell-1})^\top\,\partial\mathcal{L}/\partial h_\ell$, y así hasta cada peso θ. Promediado sobre un lote de $B = 32$ radiografías, da el gradiente del paso t:

$$g_t = \frac{1}{B}\sum_{i=1}^{B}\sum_{c=1}^{14}\frac{\partial \mathcal{L}_i}{\partial z_{ic}}\,\frac{\partial z_{ic}}{\partial \theta}. \tag{5}$$

Actualización con AdamW. Con g_t, AdamW pasa de los pesos θ_{t-1} a θ_t (un paso por lote, 2,437 por época):

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1-\beta_1)\,g_t, \qquad v_t = \beta_2 v_{t-1} + (1-\beta_2)\,g_t^2, \\ \hat{m}_t &= \frac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \frac{v_t}{1-\beta_2^t}, \\ \theta_t &= \theta_{t-1} - \eta_t\Big(\frac{\hat{m}_t}{\sqrt{\hat{v}_t}+\epsilon} + \lambda\,\theta_{t-1}\Big), \end{aligned} \tag{6}$$

con las operaciones peso por peso, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$, el decaimiento $\lambda = 0.05$ y η_t la tasa de aprendizaje. m_t promedia el gradiente (la dirección) y v_t su cuadrado (la escala); $\hat{m}_t$ y $\hat{v}_t$ corrigen que empiecen en cero. Al dividir entre $\sqrt{\hat{v}_t}$, cada peso da pasos de tamaño parecido aunque su gradiente sea grande o pequeño. La "W" es que el decaimiento $\lambda\,\theta_{t-1}$ se resta aparte, sin pasar por esa división.

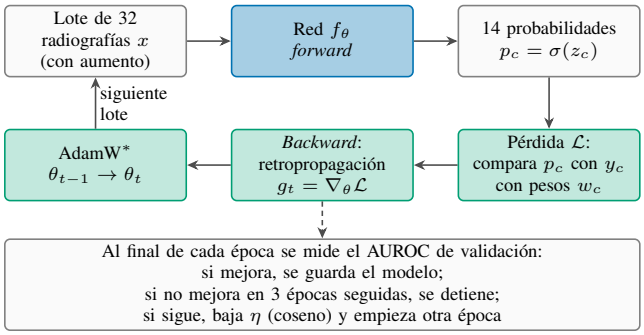


Fig. 2. Ciclo de entrenamiento, igual para los cuatro modelos. Una época recorre las 77,988 radiografías de entrenamiento en lotes de 32 (2,437 pasos). *AdamW es el descenso de gradiente del curso, $\theta_t = \theta_{t-1} - \eta\, g_t$, con tres agregados: memoria de la dirección del gradiente ($\hat{m}_t$), un paso a la medida de cada peso (se divide entre $\sqrt{\hat{v}_t}$) y un decaimiento que encoge un poco los pesos ($\lambda\, \theta_{t-1}$); ver (6).

Tabla II
MODELOS QUE CONSIDERÉ Y POR QUÉ ELEGÍ CUATRO

Modelo	Familia	Decisión
DenseNet-121	CNN	**elegido**: la CNN de CheXNet
ResNet-50, EfficientNet-B0, ConvNeXt-T	CNN	ya tenía la CNN de referencia
DeiT-S	Transformer puro	**elegido**: atención global, sin localidad
DeiT-Tiny	Transformer puro	menos preciso en ImageNet
Swin-T	Transformer jerárquico	**elegido**: atención en ventanas
CoAtNet-0	Híbrido	**elegido**: convolución y luego atención
MobileViT-S, EdgeNeXt-S	Híbridos ligeros	pensados para celulares
MaxViT-T	Híbrido	no cabía en la GPU de la laptop (lotes de 32)
DINOv2	Transformer	otro preentrenamiento: rompe la misma fuente
Versiones Base y Large	—	demasiado lentas para el plazo

Calendario y criterio de paro. La tasa de aprendizaje empieza en $\eta_0 = 10^{-4}$ y baja con un coseno a lo largo de $T = 10$ épocas; en la época $e = 1, \ldots, T$ vale

$$\eta_e = \frac{\eta_0}{2}\left(1 + \cos\frac{\pi\,(e-1)}{T}\right), \tag{7}$$

de η_0 en la primera época a $0.024\,\eta_0$ en la décima. El criterio de paro (*early stopping*) es el de la Fig. 2. Entrené en precisión mixta (16 bits), con la pérdida escalada para que los gradientes pequeños no se vuelvan cero.

D. Los cuatro modelos

Por qué estos cuatro. De diez candidatos de timm (Tabla II) elegí uno por familia con tres criterios: cubrir las cuatro familias, para separar el efecto de la localidad; partir del mismo preentrenamiento, ImageNet-1k, para que la comparación fuera justa; y caber en la GPU con lotes de 32 y en el tiempo del proyecto. Como CNN elegí DenseNet-121, la de CheXNet; de las otras familias, las variantes pequeñas, de costo parecido. La Fig. 3 muestra el flujo de cada arquitectura, y la Tabla VIII, su tamaño y su costo.

DenseNet-121 (CNN). Una convolución recorre la imagen con filtros pequeños (3×3) que comparten pesos en todas las posiciones: trae de fábrica la noción de vecindad. Cada salida es la suma de pesos por píxeles de la ventana, $z_{ij} = \sum_{u,v} w_{uv}\, x_{i+u,\,j+v} + b$, igual que en los filtros clásicos como Sobel; la diferencia es que aquí nadie escoge los w_{uv}: son parte de los pesos θ y se calculan con el ciclo de la Fig. 2 (Sección IV-C). En una DenseNet [5], la capa ℓ de cada bloque recibe la concatenación de los mapas de todas las anteriores,

$$x_\ell = H_\ell\big([x_0, x_1, \ldots, x_{\ell-1}]\big), \tag{8}$$

donde $[\cdot]$ es la concatenación por canales y H_ℓ es BN–ReLU–conv 1×1 (128 canales)–BN–ReLU–conv 3×3, que agrega $k = 32$ canales nuevos. Así cada capa reutiliza los rasgos de las anteriores y el gradiente llega por caminos cortos a las primeras capas; las transiciones reducen a la mitad los canales, el alto y el ancho. Implementé la red a mano siguiendo el tutorial de DenseNet del curso: con ReLU, carga los 727 tensores de ImageNet de timm y produce exactamente la misma salida. La red que entrené es esa implementación con LeakyReLU 0.01.

DeiT-S (Transformer puro). Parte la imagen en 196 parches de 16×16, convierte cada uno en un vector de 384 números, más su posición, y agrega un token de clase, [CLS], que al final resume la imagen. Doce bloques aplican autoatención y una MLP; en la autoatención cada parche se compara con todos los demás:

$$\text{Atención}(Q, K, V) = \text{softmax}\Big(\frac{QK^\top}{\sqrt{d_k}}\Big)V, \tag{9}$$

con Q, K y V proyecciones lineales de los 197 vectores y $d_k = 64$ (6 cabezas). Cada fila de la softmax suma 1 y dice cuánto atiende un parche a cada uno de los demás. Desde la primera capa cualquier parche puede atender a cualquier otro: la vecindad la tiene que aprender de los datos.

Swin-T (Transformer jerárquico). Parte la imagen en parches de 4×4 y calcula la atención solo dentro de ventanas de 7×7 parches, que se desplazan de un bloque al siguiente para conectar ventanas vecinas. Entre etapas fusiona cada grupo de 2×2 parches, y el mapa pasa de 56×56 a 7×7 como en una CNN. Recupera así la localidad, con un costo proporcional al número de parches y no a su cuadrado. En la última etapa la ventana ya cubre todo el mapa.

CoAtNet-0 (híbrido). Usa convoluciones en las etapas S1 y S2, donde importan los detalles locales: bloques MBConv, que expanden los canales con una conv 1×1, filtran cada canal por separado con una 3×3 y los vuelven a reducir, con una conexión residual. En S3 y S4, donde importa relacionar regiones lejanas, usa atención sobre todo el mapa con un término aprendido B que depende solo de la posición relativa, $\text{softmax}(QK^\top/\sqrt{d_k} + B)V$. Usé la variante de timm *coatnet_0_rw_224*, con 7 bloques en S3 en lugar de los 5 del original [7].

E. Protocolo

Los cuatro modelos comparten todo menos la arquitectura: datos, aumentos y normalización (Sección III-B), el ciclo y la receta (Sección III-C), los pesos de ImageNet-1k de timm, la

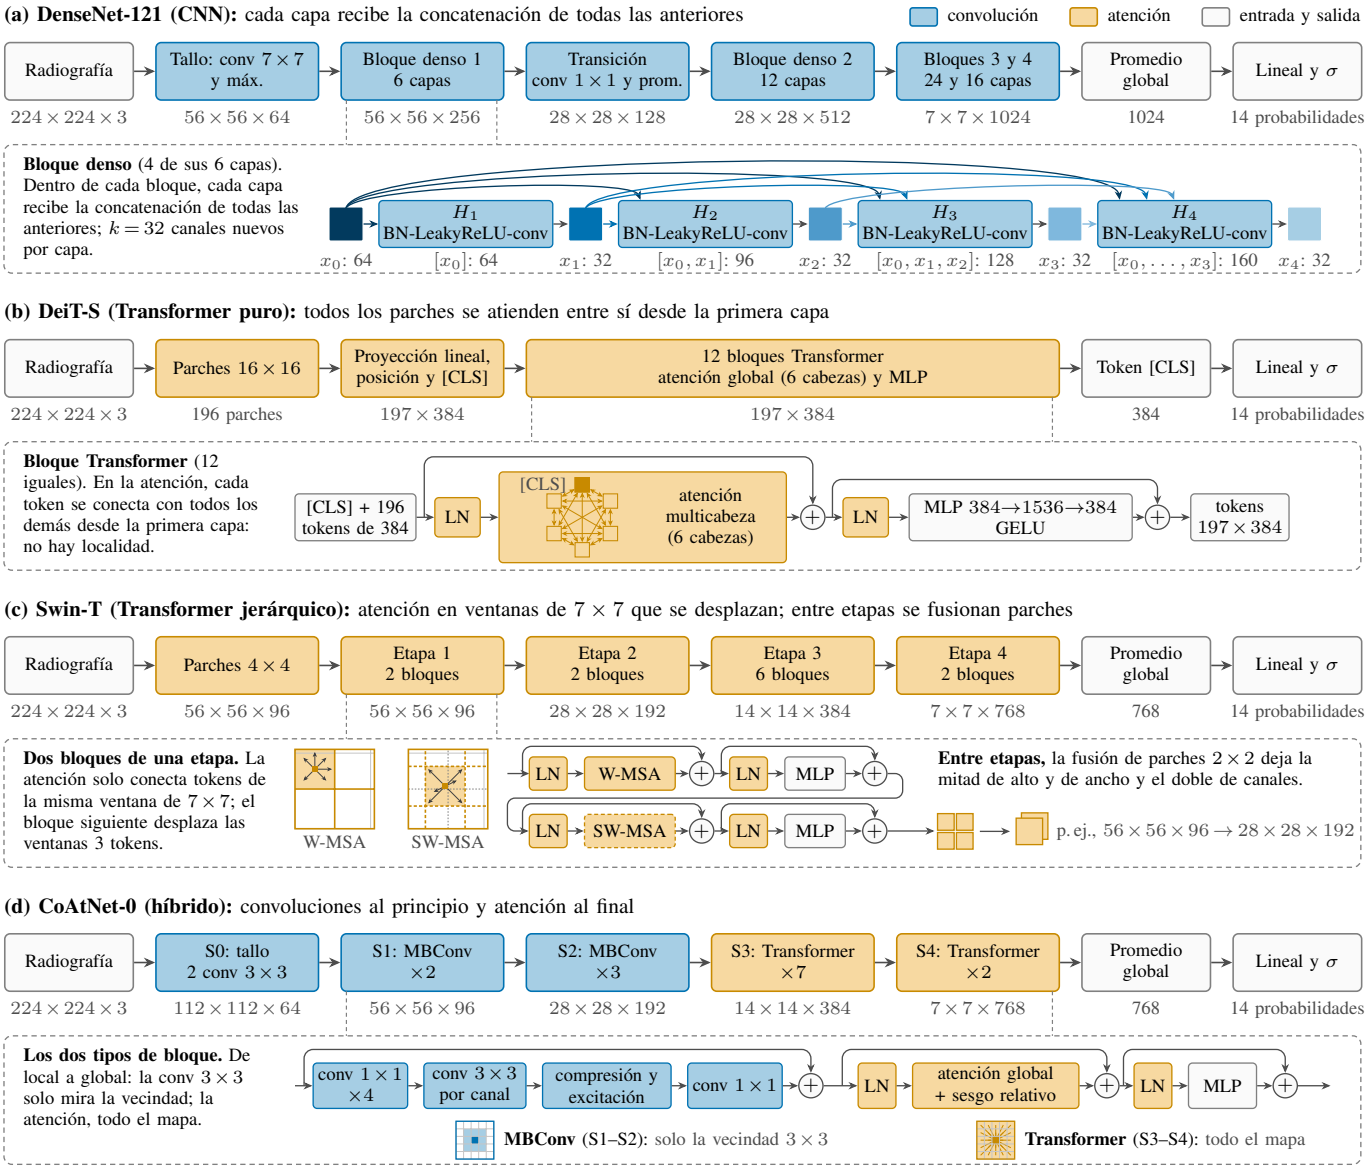


Fig. 3. Flujo de los cuatro modelos, desde la radiografía hasta las 14 probabilidades; debajo de cada etapa, el tamaño del mapa (alto × ancho × canales). Bajo cada fila, en un marco punteado, qué pasa dentro de un bloque: cómo se comunican los mapas o los tokens. Las cuatro redes terminan igual: un resumen de toda la imagen, una capa lineal nueva de 14 salidas y la sigmoide.

semilla 42 y cuDNN determinista. Con el 100 %, entrené cada modelo en una Tesla T4 de 16 GB en Kaggle. La muestra del 25 % (6,302 pacientes, 19,934 imágenes; misma validación y mismo test) la entrené con la misma receta en una RTX 4050 de 6 GB.

F. Métricas: por qué el AUROC

El reto es el desbalance: de las 358,344 respuestas del test (25,596 radiografías × 14 enfermedades), una fracción 0.925 es "no", y Hernia aparece solo en 86 radiografías. Una buena métrica debe premiar al modelo por encontrar a los enfermos, no por repetir la respuesta más común; la Tabla III compara cada métrica con una regla que no mira la imagen.

Tabla III
QUÉ MIDE CADA MÉTRICA Y CUÁNTO OBTIENE UNA REGLA QUE NO MIRA LA IMAGEN (TEST)

Métrica	Qué mide	¿Umbral?	Sin mirar la imagen	Uso aquí
Accuracy	respuestas correctas	sí	0.925 (siempre "sano")	se reporta
F1	aciertos sobre los enfermos	sí	0 (siempre "sano"), 0.134 (siempre "enfermo")	secundaria
Brier (estilo RMSE)	probabilidades creíbles	no	0.067 (siempre la prevalencia)	calibración
AUROC	enfermos por encima de sanos	no	0.500 (cualquier regla)	**principal**

Accuracy. Decir siempre "sano" acierta 0.925 por enfermedad y 0.387 de las radiografías completas, más que cualquier

modelo (0.879–0.881 por enfermedad): con este desbalance la accuracy mide qué tan rara es la enfermedad más que qué tan bueno es el modelo. Además depende del umbral: marcar menos enfermedades la sube aunque se detecten menos enfermos. La reporto porque la piden los lineamientos, con el umbral que maximiza el F1 en validación.

F1. Solo mira a los enfermos: combina la precisión P (de los marcados, cuántos la tienen) y la sensibilidad R (de los que la tienen, cuántos se marcan),

$$F_1 = \frac{2PR}{P+R}, \tag{10}$$

y no cuenta los verdaderos negativos, así que decir siempre "sano" da 0. Pero depende del umbral y de la prevalencia: con pocos casos, como Hernia, unos cuantos errores lo mueven mucho. La uso como métrica secundaria (F1 macro: promedio de las 14 enfermedades).

***Brier score* (un estilo de RMSE).** Mide si las probabilidades son creíbles (calibración), con el error cuadrático medio entre probabilidad y etiqueta (el RMSE sin la raíz):

$$\text{Brier} = \frac{1}{14N}\sum_{i=1}^{N}\sum_{c=1}^{14}(p_{ic} - y_{ic})^2. \tag{11}$$

Mezcla ordenar bien y dar probabilidades realistas, y con el desbalance premia a quien predice números chicos: decir siempre la prevalencia da 0.067, mejor que los modelos sin calibrar (0.079–0.084), que inflan sus probabilidades por la pérdida ponderada. Por eso aquí solo mide la calibración, que corregí con el escalado de Platt, $p'_c = \sigma(a_c z_c + b_c)$, con $a_c > 0$ y b_c ajustados en validación.

AUROC. Es la probabilidad de que el modelo le dé más puntaje a una radiografía con la enfermedad, x^+, que a una sin ella, x^-, elegidas al azar:

$$\text{AUROC}_c = P\big(p_c(x^+) > p_c(x^-)\big), \tag{12}$$

$$\overline{\text{AUROC}} = \frac{1}{14}\sum_{c=1}^{14}\text{AUROC}_c. \tag{13}$$

Gana justo donde fallan las otras: no necesita umbral; no depende de la prevalencia, porque cualquier regla que no mire la imagen da 0.5 en Infiltration y en Hernia, así que promediar las 14 enfermedades es justo; y solo usa el orden de los puntajes, así que no lo cambian ni la pérdida ponderada ni el escalado de Platt. Es, además, la métrica de la Tabla I.

El ruido. A cada AUROC le calculé su intervalo de confianza de 95 % con 200 remuestreos con reemplazo de los pacientes del test (no de las radiografías, que dentro de un paciente no son independientes), y para comparar dos modelos remuestreé los mismos pacientes en ambos (intervalo pareado). El ruido del entrenamiento lo estimé aparte, con otras semillas en una muestra de pacientes (Sección IV-G). Las etiquetas también traen ruido, porque se extrajeron de los informes de forma automática [8].

Para la interpretabilidad usé Grad-CAM [9]: si A^k es el mapa k de una capa, de $H \times W$ posiciones, cada mapa se pesa con el gradiente promedio del logit de la enfermedad y se conserva solo lo que lo aumenta,

$$\alpha_k = \frac{1}{HW}\sum_{i,j}\frac{\partial z_c}{\partial A^k_{ij}}, \qquad M_c = \text{ReLU}\Big(\sum_k \alpha_k A^k\Big), \tag{14}$$

Ese ReLU es parte de Grad-CAM y no la activación de la red: deja solo las zonas que suben el puntaje de la enfermedad. Calculé M_c en la última etapa de cada red y lo interpolé a 224×224. En el *pointing game*, un acierto es que el punto más caliente de M_c caiga dentro de la caja del radiólogo (984 cajas de 8 enfermedades en 880 radiografías del test).

G. Código reproducible y documentación

Escribí el código en el estilo didáctico del curso: cada celda empieza con un bloque que explica qué hace y por qué, y las ideas clave (la pérdida ponderada, AdamW, el AUROC y cada arquitectura) van con sus fórmulas junto al código. El ciclo de entrenamiento lo escribí a mano, como en los notebooks del Módulo 8, así que cada paso de la Fig. 2 se sigue en el código. Usé solo datos públicos, semilla fija y cuDNN determinista. Los notebooks son: 00 (mi DenseNet-121 hecha a mano y su verificación); M8_DenseNet121-LeakyReLU, M8_DeiT-S, M8_Swin-T y M8_CoAtNet-0 (cada modelo con el 100 % de los pacientes); M8_DenseNet121 (la versión con ReLU, para comparar); 01 (muestra del 25 %); 02_evaluacion_final (evaluación, tablas y figuras); 03 (receta, con la muestra pequeña); 04 (pesos al azar, con la muestra pequeña) y 05 (gradiente; aumento de datos y semillas, con la muestra más grande). En el README dejé el entorno, el orden en que hay que correrlos y de dónde sale cada tabla y figura.

IV. Resultados experimentales

A. Contexto: la muestra del 25 % contra el 100 %

Como contexto, la Tabla IV compara la muestra del 25 % de los pacientes con el 100 %: al pasar al 100 %, los cuatro ganan entre 0.042 y 0.051 de AUROC, más que los 0.004 que separan a las tres mejores, y DeiT-S es la que menos gana. Todas las cifras que siguen son del 100 %, salvo las de las Secciones IV-G y IV-H, que usan muestras.

Tabla IV
AUROC DE TEST: MUESTRA DEL 25 % CONTRA 100 % DE LOS PACIENTES

Modelo	25 %	100 %	Ganancia
DenseNet-121	0.759	0.805	+0.046
DeiT-S	0.742	0.785	+0.042
Swin-T	0.764	0.808	+0.044
CoAtNet-0	0.757	0.809	+0.051

La ganancia se calcula con los valores sin redondear. La muestra del 25 % se entrenó en la laptop con la misma receta, y en ella DenseNet-121 usa ReLU.

B. Desempeño con el 100 % de los pacientes

La Tabla V resume el desempeño. Contra DenseNet-121, la diferencia de AUROC con su intervalo de 95 % pareado es: Swin-T, -0.000 a +0.007; CoAtNet-0, +0.001 a +0.007; DeiT-S, -0.025 a -0.016. CoAtNet-0 queda por encima de

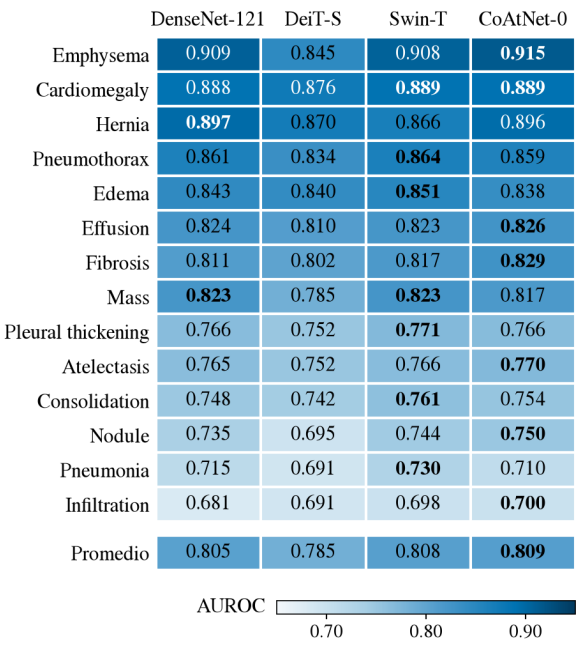


Fig. 4. AUROC en test por enfermedad y modelo, de la enfermedad más fácil a la más difícil (promedio de los cuatro modelos); en negritas, el mejor modelo de cada fila. La última fila es el promedio.

DenseNet-121 con un intervalo pareado que no cruza el cero, y Swin-T queda en el límite. Pero ese intervalo no incluye el ruido entre semillas (0.005), así que entre las tres mejores, a 0.004 o menos, la diferencia es pequeña; solo DeiT-S queda claramente abajo.

Accuracy contra AUROC. La accuracy no sigue al AUROC: aunque es el peor en AUROC, DeiT-S empata en accuracy con DenseNet-121 y Swin-T (0.879 por enfermedad; CoAtNet-0, 0.881), porque marca menos enfermedades por radiografía (1.66 contra 1.77 de DenseNet-121) y detecta menos enfermos (sensibilidad media 0.36 contra 0.42). El escalado de Platt baja el *Brier score* de los cuatro a 0.057–0.059, por debajo de la referencia de prevalencia (0.067), sin cambiar el AUROC.

Por enfermedad (Fig. 4), en promedio de los cuatro modelos las más fáciles son Emphysema, Cardiomegaly y Hernia, y las más difíciles Pneumonia y Infiltration. Emphysema y Nodule son las que más separan a los modelos.

C. Interpretabilidad

En el *pointing game* (Tabla VI), Grad-CAM acierta en una fracción de 0.233 (CoAtNet-0) a 0.381 (Swin-T) de los casos, contra 0.218 de apuntar siempre al centro. Esa referencia está dominada por Cardiomegaly, donde el corazón crecido ocupa el centro: ahí acierta 97 % de las veces y concentra el 66 % de sus aciertos. Sin Cardiomegaly, el centro acierta 0.087, y DenseNet-121, DeiT-S y Swin-T, de 0.193 a 0.290, más del doble. CoAtNet-0 apenas supera a la referencia (0.107): sus mapas son los más difusos, y no aislé la causa; no basta con que termine en atención, porque la última etapa de Swin-T también atiende a todo su mapa y es la que mejor localiza. Con un mapa de 14×14 (tercer bloque denso), DenseNet-121 sube a 0.398, pero en Swin-T la penúltima etapa localiza peor (0.273; Fig. 5).

Qué aprenden los filtros. Los filtros clásicos se escogen a mano: Sobel resalta bordes, el laplaciano el detalle fino y un promedio desenfoca (Fig. 6a). En una CNN, en cambio, los filtros parten de ImageNet y la retropropagación los ajusta. Aun así, la primera capa de DenseNet-121 terminó con detectores de bordes en varias orientaciones, de manchas y de texturas (Fig. 6b), y sus filtros 5 y 1 responden a la radiografía como el Sobel horizontal y el vertical (correlación de 0.68 y 0.68; Fig. 6c). Las capas siguientes ya no tienen una matriz clásica equivalente: cada filtro 3×3 de una capa densa tiene $3 \times 3 \times 128 = 1,152$ pesos y combina 128 mapas que ya son respuestas de otros filtros.

Al ajustar DenseNet-121 a radiografías (Tabla VII), la primera capa casi no cambió (6.0 %; similitud coseno de 0.998 con sus filtros de ImageNet): detectar bordes sirve igual en una fotografía que en una radiografía. El cambio crece con la profundidad hasta 37.7 % en el último bloque, donde estaban los detectores de objetos de ImageNet: los detectores generales se conservan y los específicos se reaprenden.

D. Costo computacional, convergencia y entrenamiento contra validación

Tener menos parámetros no implica ser más rápido (Tabla VIII): DenseNet-121 es la más ligera (7.0 M de parámetros), pero cada capa concatena todos los mapas anteriores y mueve mucha memoria, así que tarda más por época que DeiT-S (393 contra 291 s) y usa tanta memoria como CoAtNet-0 (3.10 GB). Swin-T y CoAtNet-0 son las más caras por época. DenseNet-121 y DeiT-S llegan a su mejor época en la 5, antes que CoAtNet-0 y Swin-T: 12,185 pasos, con la tasa ya en $0.65\,\eta_0$.

En la Fig. 7, después de su mejor época los cuatro modelos se sobreajustan: la pérdida de entrenamiento sigue bajando y la de validación se estanca o sube, señal de que el modelo se vuelve demasiado seguro de sus probabilidades; por eso hizo falta calibrarlo. La pérdida no llega a cero, ni debe: las etiquetas salieron de informes con errores, cada radiografía suma 14 términos con pesos que castigan más los positivos raros, y bajarla más solo se logra memorizando. Aun así, la de validación baja de 0.480, la de una probabilidad constante que no mira la imagen, a entre 0.363 y 0.381.

E. Generalización

El AUROC baja de validación a test en los cuatro modelos, entre 0.020 y 0.030. La validación sale de la misma lista oficial que el entrenamiento, pero el test oficial es otra población: sus pacientes tienen una mediana de 12 estudios previos contra 2, y 57 % de proyecciones AP (portátiles, típicas del paciente hospitalizado) contra 35 %. En validación, la primera radiografía de cada paciente y las de seguimiento dan un AUROC parecido (0.805–0.824 y 0.807–0.829); en test, la primera da 0.842–0.863 y las de seguimiento 0.774–0.799 (Tabla IX): la caída se concentra en las de seguimiento. Los

Tabla V
RESULTADOS EN EL TEST OFICIAL

Modelo	AUROC val.	AUROC test	IC 95 %	F1 macro	Acc. por enf.	Acc. exacta	Brier	Brier calibrado
DenseNet-121	**0.835**	0.805	0.799–0.811	**0.344**	0.879	0.187	**0.079**	**0.057**
DeiT-S	0.815	0.785	0.776–0.791	0.284	0.879	**0.228**	0.080	0.059
Swin-T	0.832	0.808	0.803–0.813	0.336	0.879	0.200	0.084	**0.057**
CoAtNet-0	0.829	**0.809**	0.803–0.814	0.340	**0.881**	0.219	**0.079**	**0.057**
Siempre "sano"	—	0.500	—	0.000	**0.925**	**0.387**	0.075	—
Siempre la prevalencia	—	0.500	—	—	—	—	0.067	—

En negritas, el mejor valor de cada columna entre los cuatro modelos; en las dos de accuracy, también la regla "siempre sano", que les gana a todos. Umbral del F1 elegido en validación para cada enfermedad. Accuracy exacta: acertar las 14 etiquetas de una radiografía. Brier: error cuadrático medio de las probabilidades (un estilo de RMSE; menor es mejor). Decir siempre "enfermo" da F1 macro 0.134.

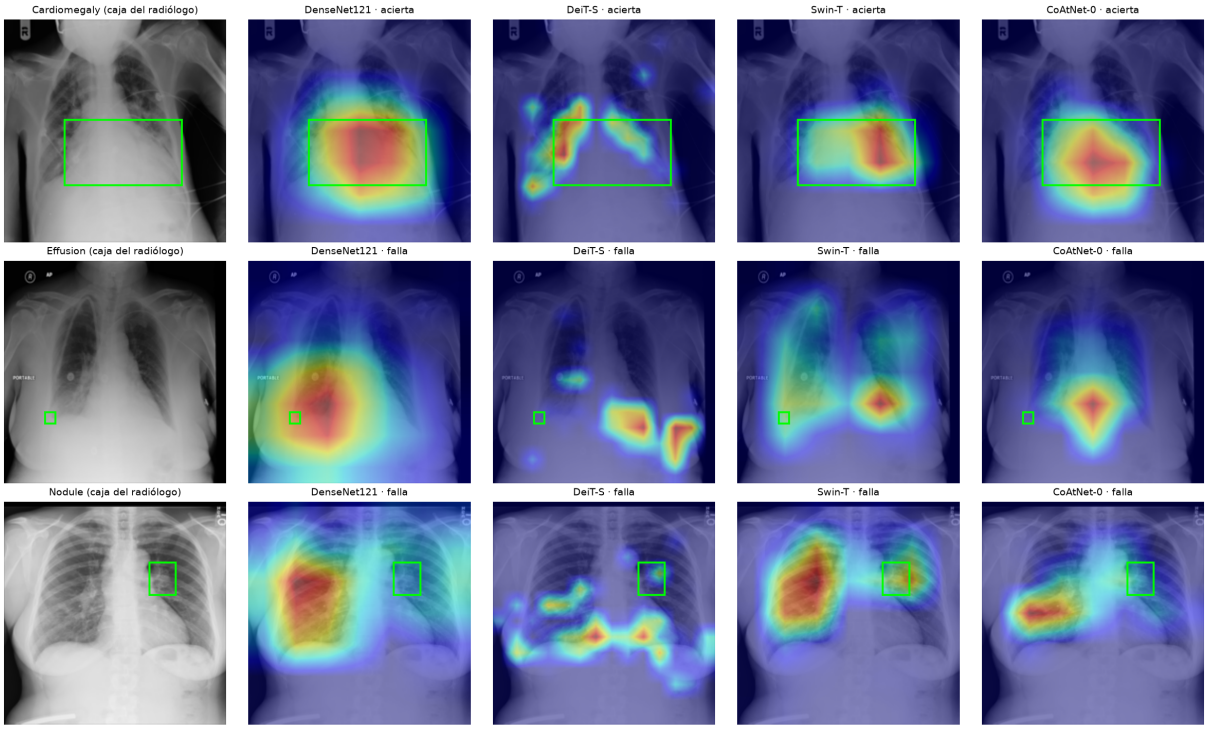


Fig. 5. Grad-CAM de cada modelo sobre tres radiografías del test, con la caja del radiólogo en verde. "Acierta" indica que el punto más caliente del mapa cae dentro de la caja (*pointing game*).

Tabla VI
GRAD-CAM CONTRA 984 CAJAS DE RADIÓLOGOS

Modelo	Pointing game	Sin Cardiom.	Energía
DenseNet-121	0.304	0.193	0.184
DeiT-S	0.325	0.227	0.199
Swin-T	0.381	0.290	0.209
CoAtNet-0	0.233	0.107	0.183
Referencia	0.218	0.087	0.078

Energía: fracción del mapa que cae dentro de la caja. La referencia apunta al centro de la imagen (pointing game) o reparte el mapa de forma uniforme (energía).

cuatro pierden en las proyecciones AP frente a PA (0.757–0.784 contra 0.780–0.807), y entre hombres y mujeres la diferencia es de 0.006 o menos.

F. ReLU contra LeakyReLU en DenseNet-121

La DenseNet-121 original usa ReLU, $\mathrm{ReLU}(z) = \max(0, z)$, en sus 121 activaciones. Si la entrada de una neurona ReLU queda negativa para todas las imágenes, su salida y su gradiente valen 0 y la neurona queda "muerta". LeakyReLU, $\max(az, z)$, deja una pendiente pequeña a para los negativos, de modo que el gradiente nunca es 0. Entrené DenseNet-121 con las dos, con el 100 % de los pacientes, la misma receta y la misma semilla. Elegí $a = 0.01$ porque es la única opción que no rompe lo aprendido en ImageNet:

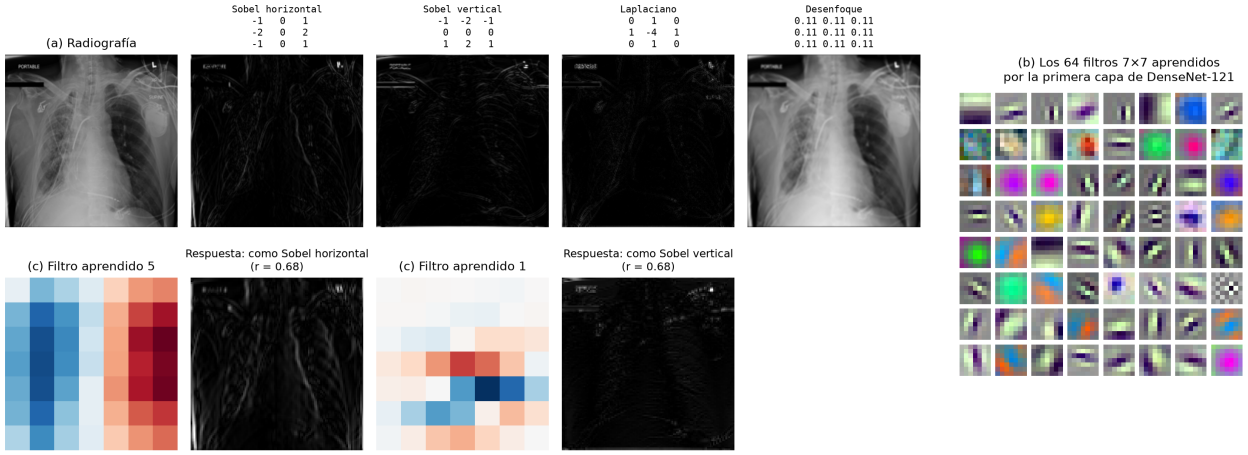


Fig. 6. (a) Filtros clásicos 3×3, escogidos a mano, aplicados a una radiografía del test; arriba de cada uno, su matriz. (b) Los 64 filtros 7×7 de la primera capa de DenseNet-121 después del entrenamiento, en color RGB: nadie escogió sus números. (c) Los dos filtros aprendidos que más se parecen a Sobel (rojo, peso positivo; azul, negativo; promedio de los tres canales) y su respuesta a la misma radiografía.

Tabla VII
CAMBIO DE LOS PESOS DE DENSENET-121 AL AJUSTARLA A RADIOGRAFÍAS

Parte de la red	Cambio
Tallo (convolución 7×7, 64 filtros)	6.0 %
Bloque denso 1	22.6 %
Bloque denso 2	30.6 %
Bloque denso 3	35.7 %
Bloque denso 4	37.7 %

$\|\theta_{\text{final}} - \theta_{\text{ImageNet}}\| / \|\theta_{\text{ImageNet}}\|$ sobre los pesos de las convoluciones de cada parte, entre los pesos de ImageNet de timm y el modelo final.

Tabla VIII
TAMAÑO Y COSTO DE ENTRENAMIENTO (TESLA T4)

Modelo	Parámetros	GFLOPs	Seg./época	Memoria (GB)	Mejor época (99 %)	Pasos a la mejor	Min a la mejor	Min totales
DenseNet-121	7.0 M	5.7	393	3.10	5 (4)	12,185	33	52
DeiT-S	21.7 M	9.2	291	1.44	5 (3)	12,185	24	39
Swin-T	27.5 M	9.0	512	2.62	7 (4)	17,059	60	85
CoAtNet-0	26.7 M	8.8	529	3.13	6 (3)	14,622	53	79

Parámetros con la capa de 14 salidas. GFLOPs por imagen de 224 píxeles. Seg./época: entrenamiento más evaluación (validación y un subconjunto fijo del 10 % del entrenamiento). Memoria: pico de memoria de GPU asignada, con lotes de 32 en precisión mixta. Entre paréntesis, la primera época que alcanza el 99 % del mejor AUROC de validación.

Tabla IX
AUROC POR SUBGRUPO

Conjunto · subgrupo	Radiog.	Sin hallazgos	4 modelos
Validación · todas	8,536	0.588	0.815–0.835
Validación · primera radiografía	2,801	0.694	0.805–0.824
Validación · seguimiento	5,735	0.535	0.807–0.829
Test · todas	25,596	0.387	0.785–0.809
Test · PA	11,096	0.435	0.780–0.807
Test · AP	14,500	0.351	0.757–0.784
Test · primera radiografía	2,797	0.710	0.842–0.863
Test · seguimiento	22,799	0.348	0.774–0.799

"4 modelos": rango de DenseNet-121, DeiT-S, Swin-T y CoAtNet-0. Primera radiografía: la del seguimiento 0 de cada paciente.

antes de entrenar, la similitud coseno entre los rasgos de la red modificada y los de la original, en 256 radiografías de validación, es 0.993 con $a = 0.01$, contra 0.391 con $a = 0.1$, 0.299 con GELU, 0.277 con SiLU y 0.230 con ELU. Antes de ver resultados fijé la regla: decidir con la validación y reportar el test de las dos.

LeakyReLU ganó en validación, 0.835 contra 0.828 (+0.007), aunque dentro del ruido: su intervalo pareado, de -0.006 a $+0.015$, cruza el cero, y entre semillas la receta varía 0.005 en la muestra más grande. Además deja menos unidades que no se activan con ninguna radiografía de validación: 5.9 %, a las que aún les llega el gradiente multiplicado por 0.01, contra 8.2 % con ReLU (7.3 % antes de entrenar, de 41,824 unidades). Por eso LeakyReLU es la activación final de DenseNet-121, aunque llega más tarde a su mejor época (5 contra 3). En test quedó -0.004 abajo (0.805 contra 0.808; intervalo de -0.007 a -0.000), y lo reporto tal cual: el test no se usó para decidir, y ese intervalo solo mide qué pacientes forman el test, no el ruido entre semillas. Con

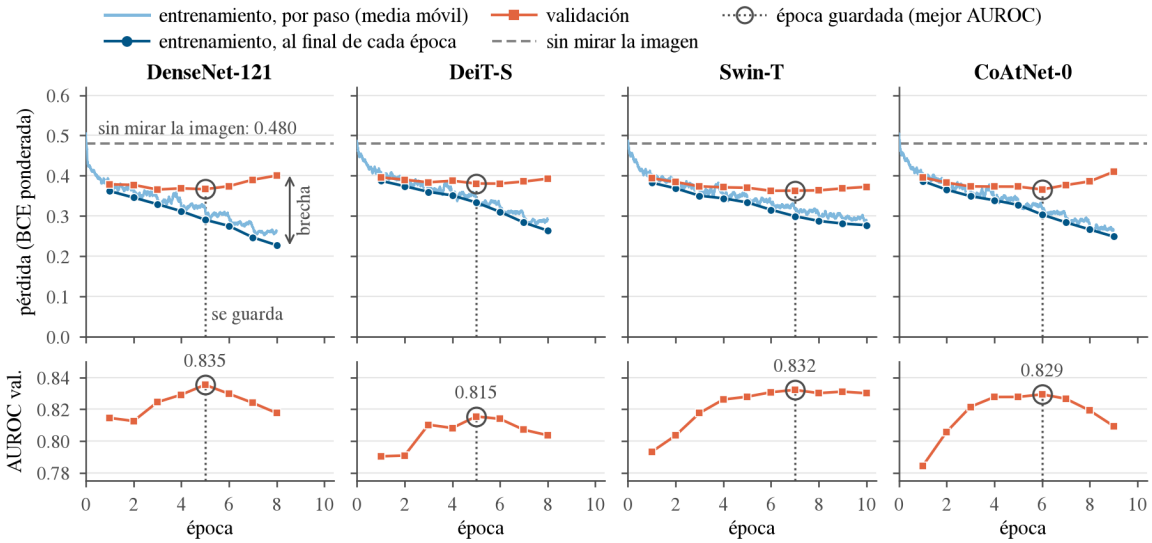


Fig. 7. Entrenamiento contra validación (100 % de los pacientes). Arriba, la pérdida ponderada (BCE con w_c) en escala lineal desde 0: la de entrenamiento en cada paso (media móvil de 250 pasos, con aumento de datos), la de entrenamiento al final de cada época en un subconjunto fijo del 10 % sin aumento, y la de validación. La línea discontinua es la pérdida en validación de la mejor probabilidad constante, que no mira la imagen (0.480). Abajo, el AUROC de validación. El círculo y la línea punteada marcan la época con mejor AUROC de validación, que es la que se conserva.

ReLU mueren pocas neuronas porque cada ReLU va después de una BatchNorm, que centra y escala sus entradas; casi todas las inactivas ya venían de ImageNet (sobre todo en el último bloque, 17.8 %). En los otros tres modelos conservé la activación: GELU y SiLU ya dejan pasar un gradiente pequeño con entradas negativas, y cambiarla en una red preentrenada puede romper lo aprendido. Es una sola semilla por activación.

G. Pruebas con muestras: receta, función de activación y aumento de datos

Para decidir la receta usé dos muestras de los pacientes de entrenamiento, con la misma validación y solo 4 épocas: una pequeña, para la receta y los pesos al azar (Sección IV-H), y una más grande, para las semillas y el aumento de datos. Estos AUROC solo sirven para comparar opciones entre sí, no contra la Tabla V.

La receta. Con la muestra pequeña probé 8 configuraciones de DenseNet-121 (Tabla X). La elegida (D) queda a 0.005 de la mejor (C), del tamaño del ruido entre corridas: en la muestra más grande, con las semillas 42, 43 y 44, obtuve 0.815, 0.810 y 0.805 (desviación estándar de 0.005). La tasa de 10^{-3} de la clase 8 (A) resultó demasiado alta para ajuste fino, y el recorte del gradiente (E) no cambió el resultado, como se espera de AdamW, que ya limita cada paso.

La función de activación. En la muestra pequeña, LeakyReLU 0.01 no mejoró (0.775 contra 0.778, dentro del ruido); por ser una prueba corta, la repetí con el 100 %.

El aumento de datos. En la muestra más grande, sin aumento DenseNet-121 baja a 0.799 (media de la receta: 0.810), y la brecha entre el AUROC de entrenamiento y el de validación casi se duplica (0.174 contra 0.092): el aumento retrasa el sobreajuste. DeiT-S también pierde sin aumento (de 0.799 a 0.784). Voltear la imagen da 0.812, dentro del ruido, así que no hacía falta (Sección III-B).

Tabla X
PRUEBAS DE LA RECETA CON DENSENET-121 (MUESTRA PEQUEÑA DE PACIENTES, 4 ÉPOCAS)

Clave	Configuración	AUROC val.
C	AdamW, lr $3 \cdot 10^{-4}$, recorte	0.783
D	**Receta del proyecto (AdamW, lr 10^{-4})**	**0.778**
H	D + sesgo inicial (prevalencia)	0.778
E	D + recorte del gradiente	0.776
G	D + LeakyReLU (pendiente 0.01)	0.775
F	D + bloques 1–2 congelados	0.770
A	Clase 8: Adam, lr 10^{-3}	0.752
B	AdamW, lr 10^{-3}, recorte	0.722

H. Pesos al azar contra ImageNet (muestra pequeña)

Entrené también DenseNet-121 y DeiT-S desde pesos al azar, con la muestra pequeña (8,227 radiografías), 4 épocas y dos tasas, 10^{-4} y 10^{-3}, para no castigar a las redes al azar con un paso pensado para ajuste fino (Tabla XI, Fig. 8). Quitar ImageNet le cuesta 0.079 de AUROC a DenseNet-121 y 0.181 a DeiT-S, 2.3 veces más, como se espera de una red que no trae de fábrica la localidad (Sección V-A); la tasa de 10^{-3} no rescata a ninguna.

Estas cifras miden qué tan rápido aprende cada arranque, no hasta dónde llega: ninguna corrida con 10^{-4} había dejado de mejorar en la época 4. Con un entrenamiento completo, Ma *et al.* [3] encuentran el mismo patrón: la CNN casi alcanza a su versión preentrenada; el Transformer puro, no.

El preentrenamiento no ayuda porque "llegue más gradiente": en la Fig. 8b, el gradiente nunca se desvanece en las 58 capas densas de DenseNet-121, gracias a la concatenación. Al azar su nivel es 39 veces menor, pero AdamW normaliza la

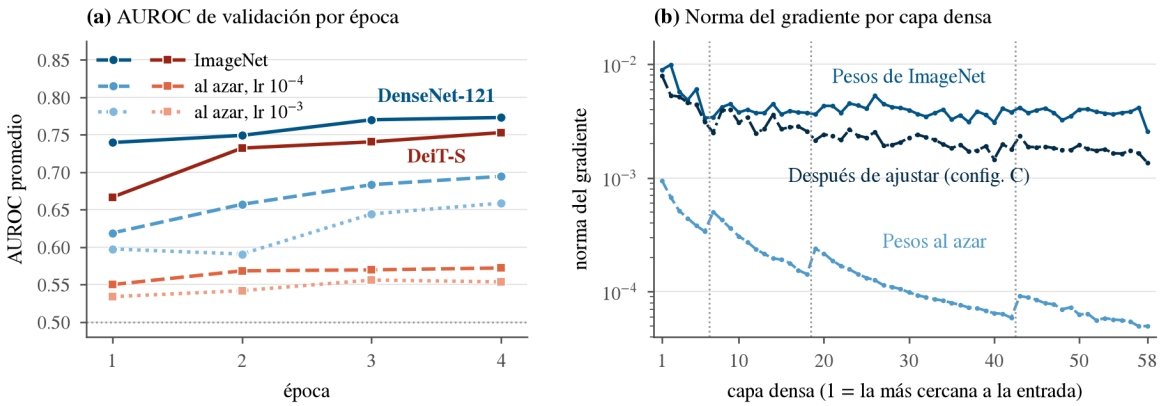


Fig. 8. (a) AUROC de validación por época de DenseNet-121 (azules, círculos) y DeiT-S (rojos, cuadros), con pesos de ImageNet (tono oscuro, línea continua) y al azar (10^{-4}: tono medio, rayas; 10^{-3}: tono claro, puntos); muestra pequeña de pacientes y 4 épocas. (b) Norma del gradiente que llega a cada capa densa de DenseNet-121, medida en modo de entrenamiento, con pesos al azar, con pesos de ImageNet y después de ajustar (configuración C de la Tabla X); el eje vertical es logarítmico y las líneas punteadas separan los bloques densos.

Tabla XI
PESOS AL AZAR CONTRA IMAGENET (MUESTRA PEQUEÑA DE PACIENTES, 4 ÉPOCAS, VALIDACIÓN)

Modelo	Arranque	lr	Mejor AUROC	Brecha	Acc. (0.5)
DenseNet-121	ImageNet	10^{-4}	0.773	0.144	0.949
DenseNet-121	al azar	10^{-4}	0.694	0.047	0.952
DenseNet-121	al azar	10^{-3}	0.659	0.024	0.953
DeiT-S	ImageNet	10^{-4}	0.753	0.090	0.949
DeiT-S	al azar	10^{-4}	0.572	0.039	0.956
DeiT-S	al azar	10^{-3}	0.556	0.015	0.956
Siempre “sano”	—	—	0.500	—	0.956

Brecha: AUROC de entrenamiento (sin aumentos) menos AUROC de validación en la época 4. Una sola semilla.

escala del gradiente de cada peso; la ventaja la explica que los rasgos de ImageNet ya sirven.

V. Discusión y conclusiones

A. Discusión

Con el 100 % de los pacientes, el Transformer puro es el único que se queda claramente atrás, y lo interpreto así: DeiT-S debe aprender de los datos la noción de vecindad, mientras que Swin-T la recupera con sus ventanas y CoAtNet-0 con sus etapas convolucionales; en la muestra pequeña, el experimento con pesos al azar va en la misma dirección. La distancia entre DeiT-S y DenseNet-121 (0.020) es del orden de la que encuentran Xiao *et al.* [4] entre ViT-S y DenseNet-121 (0.026), que la cierran preentrenando el ViT con radiografías. Además, mi receta usa un aumento ligero y DeiT se diseñó con aumentos mucho más fuertes [2]: la comparación es justa en protocolo, pero puede desfavorecerlo.

Los tres mejores modelos (0.805–0.809) quedan un poco debajo del Swin-B con ImageNet-1k de [3] (0.817, promedio de 10 corridas), un modelo más grande, y del Swin-B preentrenado con radiografías (0.830); el 0.841 de CheXNet no es comparable (Tabla I). La caída de validación a test indica que una validación de la misma lista que el entrenamiento sobreestima el desempeño en pacientes hospitalizados.

La ponderación de la pérdida ayuda a detectar las enfermedades raras, pero infla las probabilidades: con prevalencia π y $w = \sqrt{(1-\pi)/\pi}$, la probabilidad constante que minimiza la pérdida ponderada ya no es π, sino

$$p^* = \frac{w\,\pi}{w\,\pi + 1 - \pi} = \frac{\sqrt{\pi}}{\sqrt{\pi} + \sqrt{1-\pi}}, \tag{15}$$

0.038 en lugar de 0.0016 en Hernia. Por eso la probabilidad media que predice DenseNet-121 en test es 0.17, contra una prevalencia de 0.075; como la deformación es creciente, no cambia el AUROC, y la calibración la corrige sin reentrenar. Con el umbral del F1, los cuatro detectan menos de la mitad de los enfermos (sensibilidad media de 0.36–0.42, especificidad de 0.90–0.91); con el umbral que en validación detecta al 90 %, en test la sensibilidad es de 0.93–0.95 con una especificidad de 0.37–0.39: sirve para priorizar estudios, no para diagnosticar. Sin mirar la imagen, una regresión logística con edad, sexo y proyección obtiene un AUROC de 0.602 (0.84 en Hernia), muy por debajo de los cuatro modelos.

Las limitaciones son una sola semilla en los modelos con el 100 % (en la muestra más grande, la misma receta varía con una desviación estándar de 0.005; Sección IV-G), etiquetas extraídas automáticamente de los informes (precisión estimada mayor a 90 % [8]), la resolución de 224 píxeles, que puede borrar hallazgos pequeños como los nódulos, y un experimento de pesos al azar corto y en una muestra pequeña, que no mide el techo de cada red.

B. Conclusiones y trabajo futuro

Con el 100 % de los pacientes, mis hallazgos principales son:

- **Las tres arquitecturas con localidad quedan muy cerca**: DenseNet-121, Swin-T y CoAtNet-0, a 0.004 o menos en AUROC; el Transformer puro (DeiT-S), 0.020 debajo de DenseNet-121.

- **DenseNet-121 es la opción más eficiente en tamaño**: casi el mismo desempeño con 3 a 4 veces menos parámetros y menos GFLOPs, aunque no es la más rápida por época.
- **DenseNet-121 usa LeakyReLU 0.01**: ganó en validación (+0.007, dentro del ruido) y deja menos unidades inactivas (5.9 % contra 8.2 %); en test quedó -0.004 abajo, pero el test no se usó para decidir. Los otros tres conservan su activación original.
- **La validación sobreestima el desempeño**: por el cambio de población, el AUROC cae de validación a test entre 0.020 y 0.030, sobre todo en las radiografías de seguimiento.
- **La accuracy engaña** cuando casi todas las respuestas son "no": hace falta el AUROC junto con líneas base que no miren la imagen.
- **Grad-CAM localiza mejor que apuntar al centro** en los cuatro modelos, aunque CoAtNet-0 apenas, y ninguno acierta en la mitad de los casos: sus mapas se leen con cautela.

Las pruebas con muestras de pacientes, que solo dan contexto, me dejan tres lecciones más:

- **Los datos pesan más que la arquitectura**: con la muestra del 25 %, los cuatro pierden entre 0.042 y 0.051 de AUROC, más de lo que los separa con el 100 %.
- **Con pocos datos, DenseNet-121 también es una opción segura**: con la muestra del 25 % queda a 0.005 de la mejor (Swin-T), del orden del ruido, y en la muestra pequeña es la que menos depende de ImageNet.
- **Cómo arrancar la optimización**: con los pesos de ImageNet, ajustando toda la red con AdamW y una tasa pequeña (10^{-4}); con 10^{-3} empeora el ajuste fino y no se rescatan las redes al azar.

Como trabajo futuro propongo varias semillas (también para ReLU contra LeakyReLU), entrenar desde cero con el 100 % para separar la velocidad del techo de cada arquitectura (y ahí comparar activaciones, que sin preentrenamiento son una elección libre), una resolución mayor (448 píxeles) y el preentrenamiento autosupervisado con radiografías [3], [4]. Para que la multimodalidad ayude haría falta información que no esté en la imagen, como el texto del informe, porque la edad, el sexo y la proyección predicen poco (AUROC de 0.602).

Referencias

[1] P. Rajpurkar *et al.*, "CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning," arXiv:1711.05225, 2017.

[2] H. Touvron *et al.*, "Training data-efficient image transformers & distillation through attention," in *Proc. ICML*, 2021, pp. 10347–10357.

[3] D. Ma, M. R. Hosseinzadeh Taher, J. Pang, N. U. Islam, F. Haghighi, M. B. Gotway, and J. Liang, "Benchmarking and boosting transformers for medical image classification," in *Domain Adaptation and Representation Transfer (DART)*, LNCS 13542, 2022, pp. 12–22.

[4] J. Xiao, Y. Bai, A. Yuille, and Z. Zhou, "Delving into masked autoencoders for multi-label thorax disease classification," in *Proc. IEEE/CVF WACV*, 2023.

[5] G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in *Proc. IEEE CVPR*, 2017, pp. 4700–4708.

[6] Z. Liu *et al.*, "Swin Transformer: Hierarchical vision transformer using shifted windows," in *Proc. IEEE/CVF ICCV*, 2021, pp. 10012–10022.

[7] Z. Dai, H. Liu, Q. V. Le, and M. Tan, "CoAtNet: Marrying convolution and attention for all data sizes," in *Advances in Neural Information Processing Systems (NeurIPS)*, 2021.

[8] X. Wang *et al.*, "ChestX-ray8: Hospital-scale chest X-ray database and benchmarks on weakly-supervised classification and localization of common thorax diseases," in *Proc. IEEE CVPR*, 2017, pp. 2097–2106.

[9] R. R. Selvaraju *et al.*, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE ICCV*, 2017.